

КРОЩЕНКО Александр Александрович

Методы обучения глубоких нейронных сетей для задач компьютерного зрения

диссертация на соискание

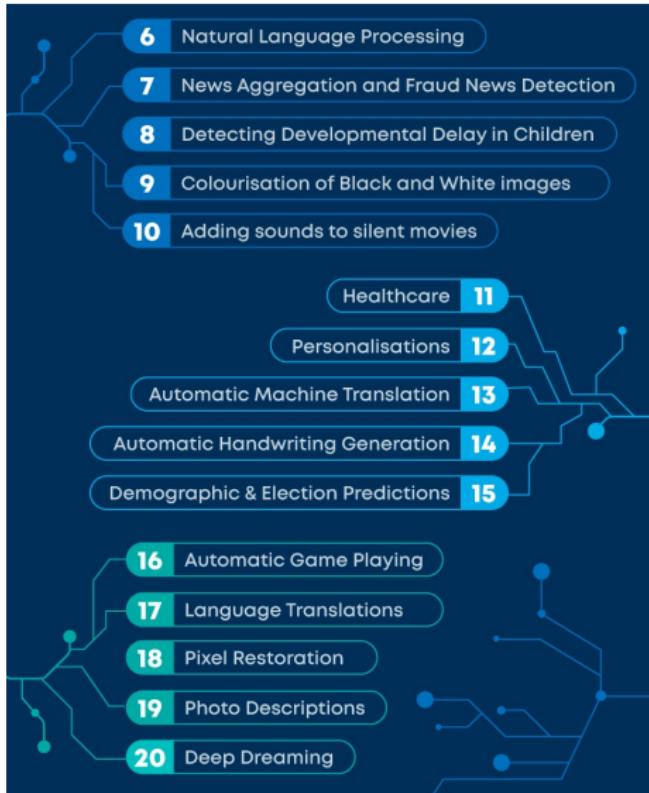
ученой степени кандидата технических наук по специальности
05.13.17 – «Теоретические основы информатики»

Научный руководитель:
д.т.н., профессор
Головко В.А.

Брест 2023

Актуальность (1)

Актуальность обучения глубоких нейронных сетей обусловлена растущим количеством приложений, в которых применяются эти модели.



Актуальность (2)

К сожалению, в настоящее время одним из основных подходов при обучении глубоких нейросетей является использование зарекомендовавших себя методов при повышенных требованиях к количеству обучающих данных, что приводит к невозможности обучения таких моделей при аппаратных ограничениях. Тем не менее сложность самих моделей продолжает расти.

- AlexNet
- VGG16
- ResNet-50
- NASNet
- SENet

Объект и предмет исследований

Цель

Разработка эффективных методов и алгоритмов для обучения глубоких нейронных сетей, используемых для решения задач компьютерного зрения, включающих распознавание маркировки продукции на конвейерной линии и определение наличия солнечных панелей на аэрофотоснимках.

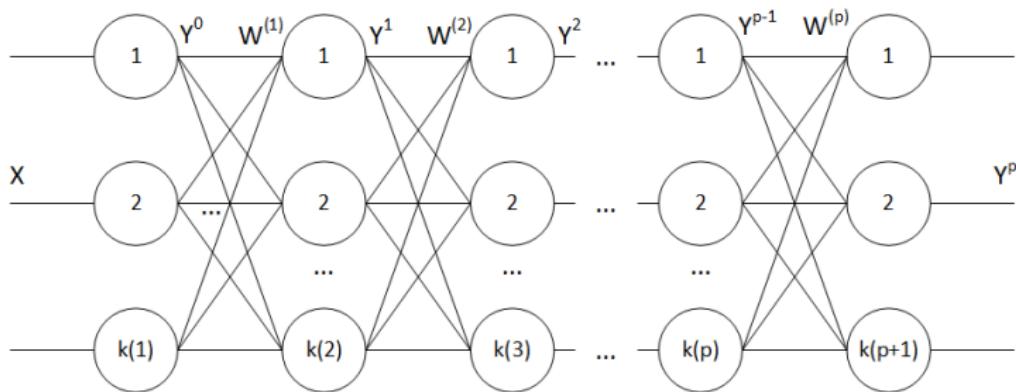
Объект исследований

Нейросетевые системы компьютерного зрения

Предмет исследований

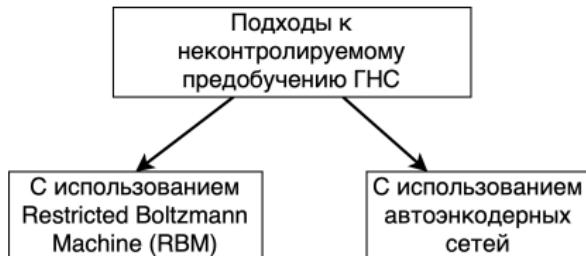
Методы и алгоритмы обучения глубоких нейронных сетей и их применение к задачам компьютерного зрения

Методы обучения ГНС

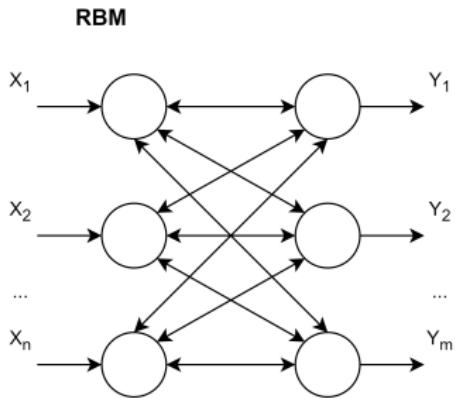


Методы обучения ГНС используют предварительное обучение (предобучение) в качестве этапа инициализирующей настройки параметров модели

- ❶ I тип – С использованием неконтролируемого предобучения;
 - ❷ II тип – С использованием предобучения на большой обучающей выборке.

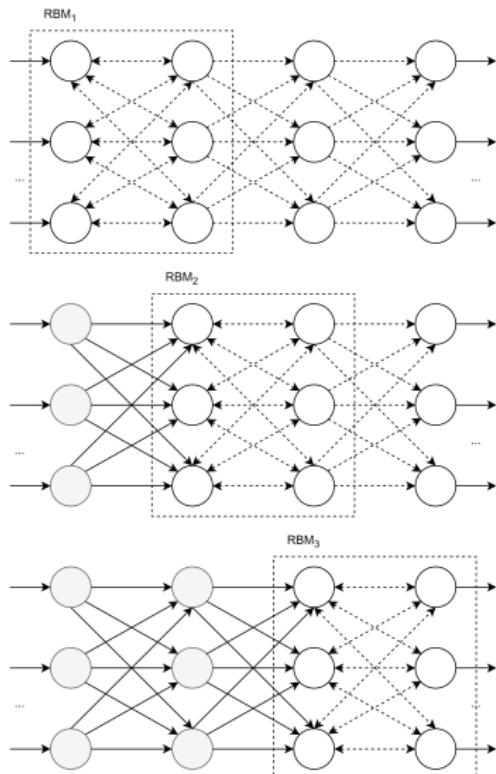


Обучение с использованием неконтролируемого предобучения на основе RBM

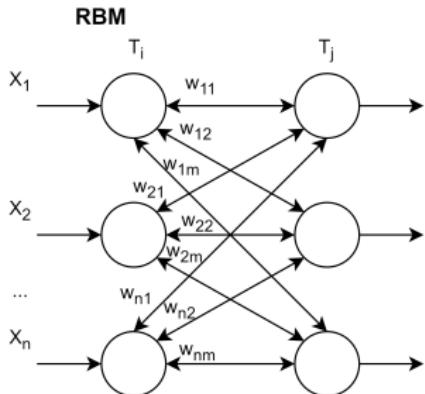


Этапы обучения:

- 1 Послойное неконтролируемое предобучение нейронной сети;
- 2 Настройка синаптических связей всей сети («доводка» параметров);



Обучение RBM



$$\ln P(x) = \ln \sum_y e^{-E(x,y)} - \ln \sum_{x,y} e^{-E(x,y)}$$

Обучение в процессе реализации процедуры CD (Contrastive Divergence):

$$x(0) \rightarrow y(0) \rightarrow x(1) \rightarrow y(1) \rightarrow \dots \\ \rightarrow x(k) \rightarrow y(k)$$

Правила обучения (случай CD-k)

$$w_{ij}(t+1) = w_{ij}(t) + \alpha(x_i(0)y_j(0) - x_i(k)y_j(k))$$

$$T_i(t+1) = T_i(t) + \alpha(x_i(0) - x_i(k))$$

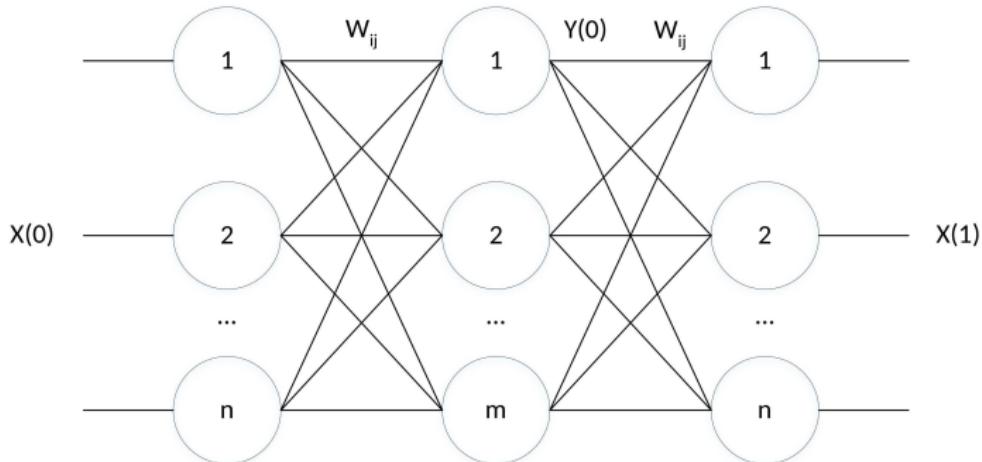
$$T_j(t+1) = T_j(t) + \alpha(y_j(0) - y_j(k)).$$

Положения, выносимые на защиту (1)

1

Метод обучения ограниченной машины Больцмана, базирующийся на эквивалентности максимизации функции правдоподобия распределения входных данных в пространстве синаптических связей и минимизации суммарной квадратичной ошибки сети при использовании линейных нейронов, что позволяет **расширить класс обучаемых моделей и повысить обобщающую способность глубоких нейронных сетей**.

Альтернативное представление RBM (1)



$$\begin{aligned} S_j(0) &= \sum_i w_{ij} x_i(0) + T_j \\ y_j(0) &= F(S_j(0)) \end{aligned}$$

$$\begin{aligned} S_i(1) &= \sum_j w_{ij} y_j(0) + T_i \\ x_i(1) &= F(S_i(1)) \end{aligned}$$

$$\begin{aligned} \dots \\ S_i(k) &= \sum_j w_{ij} y_j(k-1) + T_i \\ x_i(k) &= F(S_i(k)) \end{aligned}$$

$$\begin{aligned} \dots \\ S_j(k) &= \sum_i w_{ij} x_i(k) + T_j \\ y_j(k) &= F(S_j(k)) \end{aligned}$$

Критерии минимизации

$$E_s(k) = \frac{1}{2L} \left(\sum_{l=1}^L \sum_{j=1}^m \sum_{p=1}^k (y_j^l(p) - y_j^l(p-1))^2 + \sum_{l=1}^L \sum_{i=1}^n \sum_{p=1}^k (x_i^l(p) - x_i^l(p-1))^2 \right)$$

$$CE_v(k) = -\frac{1}{L} \sum_{l=1}^L \sum_{p=1}^k \sum_{i=1}^n x_i^l(p-1) \log(x_i^l(p)) + (1 - x_i^l(p-1)) \log(1 - x_i^l(p))$$

$$CE_h(k) = -\frac{1}{L} \sum_{l=1}^L \sum_{p=1}^k \sum_{j=1}^m y_j^l(p-1) \log(y_j^l(p)) + (1 - y_j^l(p-1)) \log(1 - y_j^l(p))$$

$$CE_s(k) = CE_h(k) + CE_v(k)$$

Теоремы об эквивалентности

Теорема 1. Максимизация функции правдоподобия распределения данных $P(x)$ в пространстве синаптических связей ограниченной машины Больцмана эквивалентна минимизации суммарной квадратичной ошибки сети в том же пространстве при использовании линейных нейронов.

Теорема 4. Максимизация функции правдоподобия распределения входных данных $P(x)$ эквивалентна минимизации кросс-энтропийной целевой функции $CE_s(k)$ в одном и том же пространстве синаптических весов ограниченной машины Больцмана.

Теорема 5. Максимизация функции правдоподобия распределения входных данных $P(x)$ эквивалентна минимизации кросс-энтропийной функции и специальному случаю минимизации среднеквадратичной ошибки в одном и том же пространстве синаптических весов ограниченной машины Больцмана:

$$\max(\ln P(x)) = \min(CE_s) = \min(E_s)$$

Метод обучения RBM: последовательное обучение

Случай CD-1:

$$w_{ij}(t+1) = w_{ij}(t) - \alpha((y_j(1) - y_j(0))F'(S_j(1))x_i(1) + (x_i(1) - x_i(0))F'(S_i(1))y_j(0)),$$

$$T_i(t+1) = T_i(t) - \alpha(x_i(1) - x_i(0))F'(S_i(1)),$$

$$T_j(t+1) = T_j(t) - \alpha(y_j(1) - y_j(0))F'(S_j(1)).$$

Случай CD-k:

$$w_{ij}(t+1) = w_{ij}(t) - \alpha \left(\sum_{p=1}^k (y_j(p) - y_j(p-1))x_i(p)F'(S_j(p)) + (x_i(p) - x_i(p-1))y_j(p-1)F'(S_i(p)) \right)$$

$$T_i(t+1) = T_i(t) - \alpha \left(\sum_{p=1}^k (x_i(p) - x_i(p-1))F'(S_i(p)) \right),$$

$$T_j(t+1) = T_j(t) - \alpha \left(\sum_{p=1}^k (y_j(p) - y_j(p-1))F'(S_j(p)) \right),$$

Метод обучения RBM: групповое обучение (1)

Случай CD-1:

$$w_{ij}(t+1) = w_{ij}(t) -$$

$$-\frac{\alpha}{L} \left(\sum_{l=1}^L (y_j^l(1) - y_j^l(0)) x_i^l(1) F'(S_j^l(1)) + (x_i^l(1) - x_i^l(0)) y_j^l(0) F'(S_i^l(1)) \right),$$

$$T_i(t+1) = T_i(t) - \frac{\alpha}{L} \left(\sum_{l=1}^L (x_i^l(1) - x_i^l(0)) F'(S_i^l(1)) \right),$$

$$T_j(t+1) = T_j(t) - \frac{\alpha}{L} \left(\sum_{l=1}^L (y_j^l(1) - y_j^l(0)) F'(S_j^l(1)) \right)$$

Метод обучения RBM: групповое обучение (2)

Случай CD- k :

$$w_{ij}(t+1) = w_{ij}(t) - \frac{\alpha}{L} \left(\sum_{l=1}^L \sum_{p=1}^k (y_j^l(p) - y_j^l(p-1)) x_i^l(p) F'(S_j^l(p)) + (x_i^l(p) - x_i^l(p-1)) y_j^l(p-1) F'(S_i^l(p)) \right)$$
$$T_i(t+1) = T_i(t) - \frac{\alpha}{L} \left(\sum_{l=1}^L \sum_{p=1}^k (x_i^l(p) - x_i^l(p-1)) F'(S_i^l(p)) \right),$$
$$T_j(t+1) = T_j(t) - \frac{\alpha}{L} \left(\sum_{l=1}^L \sum_{p=1}^k (y_j^l(p) - y_j^l(p-1)) F'(S_j^l(p)) \right)$$

Метод обучения CRBM: последовательное обучение

Случай CD-1:

$$w_{ij}(t+1) = w_{ij}(t) - \alpha((y_j(1) - y_j(0))F'(S_j(1)) \circledast x_i(1) + (x_i(1) - x_i(0))F'(S_i(1)) \circledast y_j(0)),$$

$$T_i(t+1) = T_i(t) - \alpha(x_i(1) - x_i(0))F'(S_i(1)),$$

$$T_j(t+1) = T_j(t) - \alpha(y_j(1) - y_j(0))F'(S_j(1)).$$

Случай CD-k:

$$w_{ij}(t+1) = w_{ij}(t) - \alpha \left(\sum_{p=1}^k (y_j(p) - y_j(p-1))F'(S_j(p)) \circledast x_i(p) + (x_i(p) - x_i(p-1))F'(S_i(p)) \circledast y_j(p-1) \right)$$

$$T_i(t+1) = T_i(t) - \alpha \left(\sum_{p=1}^k (x_i(p) - x_i(p-1))F'(S_i(p)) \right),$$

$$T_j(t+1) = T_j(t) - \alpha \left(\sum_{p=1}^k (y_j(p) - y_j(p-1))F'(S_j(p)) \right),$$

Сравнение методов: используемые выборки



Характеристики:

MNIST

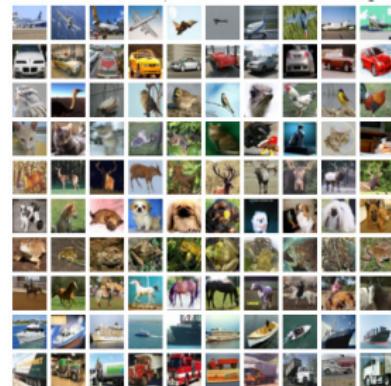
Количество классов: 10

Обучающая часть: 50.000 из.

Валидационная часть: 10.000 из.

Размеры изображений: 28X28

Цветовая модель: Grayscale



Характеристики:

CIFAR10/CIFAR100

Количество классов: 10/100

Обучающая часть: 50.000 из.

Валидационная часть: 10.000 из.

Размеры изображений: 32X32

Цветовая модель: RGB

Используемые программные средства реализации

- 1 Python

Условные обозначения для исследуемых моделей

Сравнение методов (MNIST): параметры эксперимента

Параметры модели:

Параметр	Значение
Архитектура	40X5X5 – 40X5X5 – 640X320 – 320X160 – 160X10
Функция активации	ReLU
Функция активации на последнем слое	Softmax
Начальная инициализация параметров	Нормальное распределение
Общее число параметров модели	299.170

Параметры обучения:

Этап	Параметр	Значение
Предобучение	Скорость обучения	0,000125
	Размер мини-батча	128
	Моментный параметр	[0,5; 0,9]
	Количество эпох обучения	30
Обучение	Скорость обучения	0,001
	Размер мини-батча	128
	Моментный параметр	0,9
	Количество эпох обучения	50

Сравнение методов (MNIST): результаты

Метод обучения	Эффективность, %
BP	99.367
REBA	99.371
HREBA	99.458
C-RBM	99.447

- BP – обучение без предобучения;
- REBA – обучение с предобучением (предлагаемый подход);
- HREBA – обучение с предобучением (гибридный подход);
- C-RBM – обучение с классическим методом предобучения).

Лучший результат: **99.53** (HREBA)

При обучении с помощью гибридного метода первый слой глубокой нейронной сети обучался как RBM с использованием классического метода обучения, а все последующие обучались предложенным методом.

Сравнение методов (CIFAR10): параметры эксперимента

Параметры модели:

Параметр	Значение
Архитектура	64X5X5 – 32X5X5 – 800X128 – 128X10 / 128X100
Функция активации	ReLU - Tanh - ReLU
Функция активации на последнем слое	Softmax
Начальная инициализация параметров	Нормальное распределение
Общее число параметров модели	159.914

Параметры обучения:

Этап	Параметр	Значение
Предобучение	Скорость обучения	0,000125
	Размер мини-батча	128
	Моментный параметр	[0,5; 0,9]
	Количество эпох обучения	30
Обучение	Скорость обучения	0,001
	Размер мини-батча	128
	Моментный параметр	0,9
	Количество эпох обучения	25

Сравнение методов (CIFAR10): результаты

Метод обучения	Эффективность, %
BP	69.74
REBA	71.20
HREBA	71.59
C-RBM	71.51

- BP – обучение без предобучения;
- REBA – обучение с предобучением (предлагаемый подход);
- HREBA – обучение с предобучением (гибридный подход);
- C-RBM – обучение с классическим методом предобучения).

Лучший результат: **72.32** (HREBA)

Сравнение методов (CIFAR100): результаты

Метод обучения	Эффективность, %
BP	36.83
REBA	38.9
HREBA	39.86
C-RBM	39.71

- BP – обучение без предобучения;
- REBA – обучение с предобучением (предлагаемый подход);
- HREBA – обучение с предобучением (гибридный подход);
- C-RBM – обучение с классическим методом предобучения).

Лучший результат: **40.26** (HREBA)

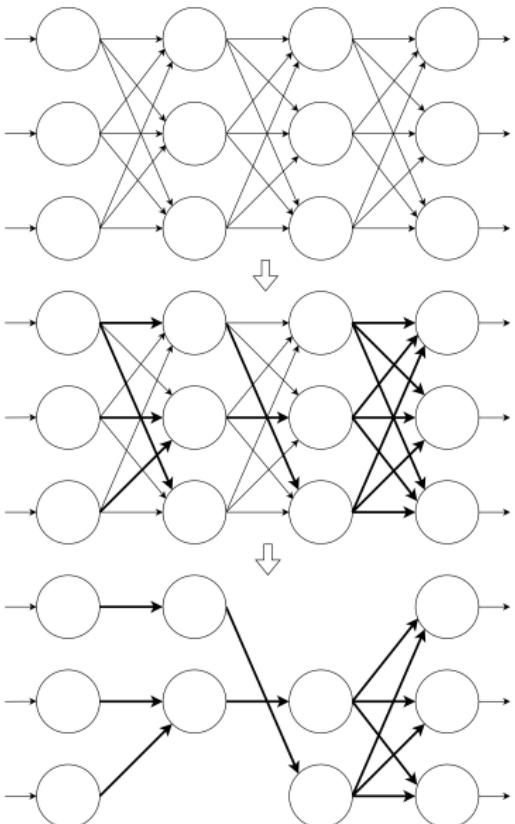
Положения, выносимые на защиту (2)

2

Алгоритм редуцирования параметров глубокой нейронной сети, базирующийся на неконтролируемом предобучении сети, что позволяет упростить ее архитектуру (путем сокращения числа настраиваемых параметров модели) без потери обобщающей способности.

Алгоритм редуцирования параметров

- 1 Неконтролируемое предобучение НС, начиная с первого слоя;
- 2 Обнуление параметров НС, значения которых попадают в интервал $[-t, t]$ для заданного $t > 0$;
- 3 Архитектурная реконфигурация НС. для каждого i -того слоя НС, кроме первого и последнего:
 - если вектор-столбец j матрицы весовых коэффициентов W_i слоя нулевой, то удалить j -тый вектор-столбец из W_i и удалить j -тую вектор-строку из W_{i+1}
 - если вектор-строка k матрицы весовых коэффициентов нулевая, то удалить k -тую строку из W_i и удалить k -тый столбец из матрицы W_{i-1}
- 4 Тонкая настройка синаптических связей полученной упрощенной архитектуры.



Алгоритм редуцирования: параметры эксперимента

Таблица 1: Основные параметры обучения

Этап	Параметр	Значение
Обучение	Скорость обучения	0.05-0.1
	Размер мини-батча	100
	Моментный параметр	0.9
	Количество эпох обучения	50-100
Предобучение	Скорость обучения	0.05-0.2
	Размер мини-батча	32-100
	Моментный параметр	[0.5, 0.9]
	Количество эпох обучения	10

Алгоритм редуцирования: результаты

784-800-800-10

Тип	Эффективность, %, C-RBM / REBA	Количество параметров, C-RBM / REBA	Редуцировано параметров, %, C-RBM / REBA
без редуц.	98.63 / 98.33	1276810 / 1276810	0/0
t=0.2	98.61 / 98.27	233760 / 279635	81.69 / 78.1
t=0.5	98.03 / 98.05	32524 / 32817	97.45 / 97.43
t=0.8	97.1 / 96.48	17061 / 12217	98.66 / 99.04

784-1600-1600-800-800-10

Тип	Эффективность, %, C-RBM / REBA	Количество параметров, C-RBM / REBA	Редуцировано параметров, %, C-RBM / REBA
без редуц.	98.76 / 98.37	5747210 / 5747210	0/0
t=0.2	98.51 / 98.55	710734 / 781103	87.63 / 86.41
t=0.5	98.01 / 98.03	54709 / 43867	99.05 / 99.24
t=0.8	96.9 / 93.08	25385 / 14914	99.56 / 99.74

Результаты архитектурной реконфигурации моделей

Исходная модель: 784-800-800-10

Параметр	Редуцированная
t=0.2	784-800-556-10
t=0.5	784-710-422-10
t=0.9	784-91-114-10

Исходная модель: 784-1600-1600-800-800-10

Параметр	Редуцированная
t=0.2	784-889-192-686-221-10
t=0.5	784-464-157-567-182-10
t=0.9	784-17-101-118-50-10

Положения, выносимые на защиту (3)

3

Нейросетевые системы компьютерного зрения,
базирующиеся на использовании предобученных моделей для
решения задач классификации и детекции – система
распознавания (в реальном режиме времени) **маркировки**
продукта на производственной линии и система
обнаружения солнечных панелей на аэрофотоснимках
(включая снимки низкого разрешения) с точностью до 87,46%.

Система распознавания маркировки

Цель разработки

Разработать систему проверки корректности нанесения маркировки на продукцию, производимую ОАО «Савушкин продукт»

Актуальность

Контроль качества маркировки необходим для контроля за свежестью продукции как со стороны покупателей, так и со стороны обслуживающего персонала супермаркетов, поскольку в большинстве случаев визуальная оценка оказывается проще и быстрее применения специализированных технических средств.

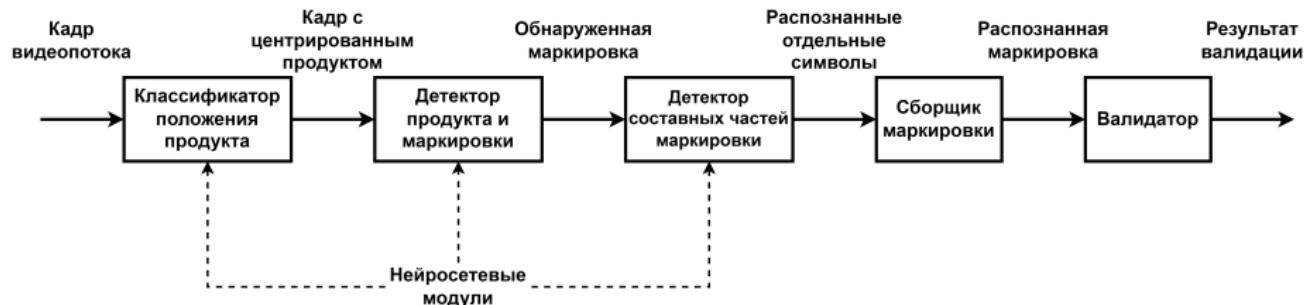


Возможные ошибки, допускаемые при нанесении маркировки

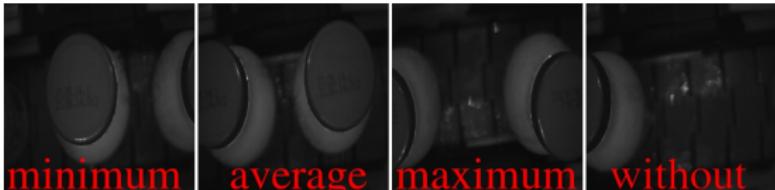
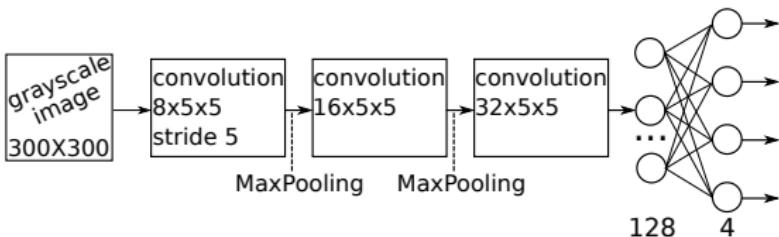
- Отсутствие краски в печатающем устройстве;
- Смазанность маркировки;
- Ошибочная дата в маркировке.

Первый тип ошибок может быть представлен различными случаями, такими как полное отсутствие маркировки или отсутствие какой-либо ее части.

Структура системы и базовые модули

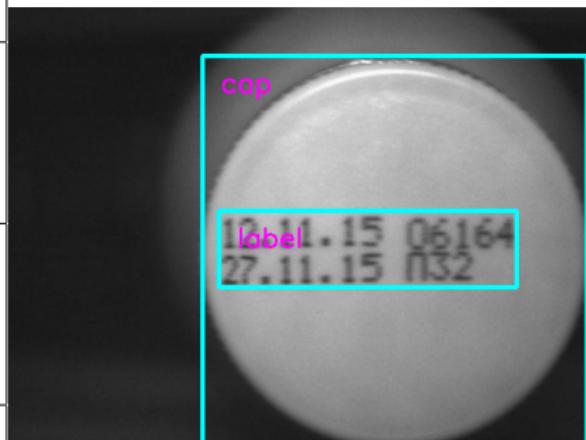


- ❶ Классификатор положения продукта
- ❷ Детектор продукта и маркировки (SSD-MobileNet)
- ❸ Детектор составных частей маркировки (SSD-MobileNet)



Результаты обучения и тестирования моделей (1)

Модель	Выборка	Тест., %
Классификатор положения продукта	Обучающая часть: 4.886 Валидационная часть: 1.303	93,27
Детектор продукта и маркировки	Обучающая часть: 652 Валидационная часть: 163	99,03
Детектор отдельных символов	Обучающая часть: 33402 (SVHN) + 825 Валидационная часть: 13068 (SVHN) + 275	92,43



Система обнаружения солнечных панелей на аэрофотоснимках

Цель разработки

Разработать систему детекции солнечных панелей на фотоснимках, полученных из выборки, собранной из Google Maps

Актуальность

Необходимость разработки специализированных решений для детекции панелей обусловлена стремлением компаний получать информацию об применении данной технологии и тем самым создавать целевое предложение.

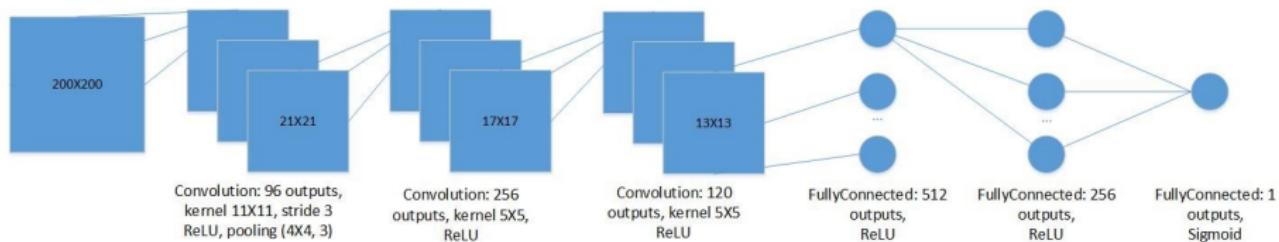
Предлагаемый алгоритм обнаружения панелей включает два основных этапа, на каждом из которых используется предобученная глубокая нейронная сеть:

- 1 Оценка наличия солнечной панели на аэрофотоснимке
- 2 Локализация солнечной панели

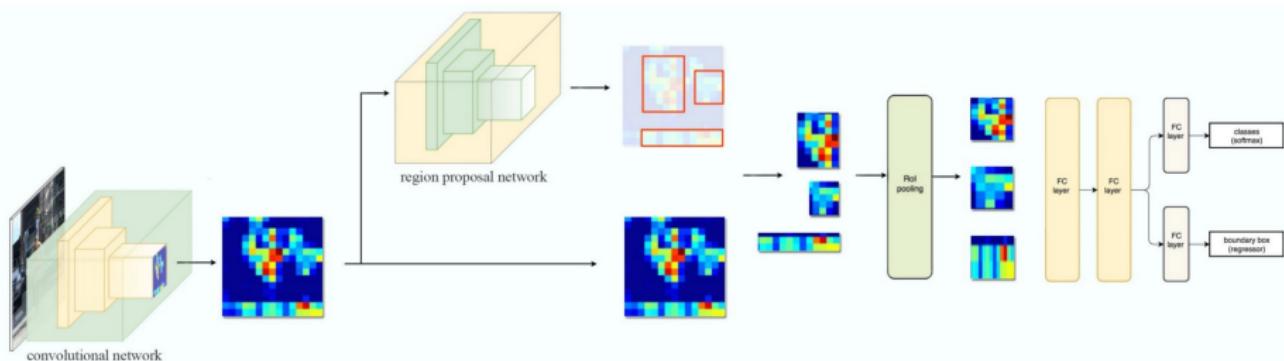


Применяемые модели

Классификатор для оценки наличия панели



Модель для детекции панели (на базе Faster R-CNN)



Результаты обучения и тестирования моделей (2)

Модель	Выборка	Тест., %
Классификатор наличия	Обучающая часть: 2.677 Валидационная часть: 670	87,46
Детектор солнечной панели	Обучающая часть: 800 Валидационная часть: 200	92,99



Связь работы с научными программами

- ❶ НИР МОРБ «Алгоритмы интеллектуального анализа и обработки больших объемов данных на основе нейронных сетей глубокого доверия» (ГБ 15/203, № госрегистрации 20150743),
- ❷ ГПНИ «Информатика и космос, научное обеспечение безопасности и защиты от чрезвычайных ситуаций» по заданию «Нейросетевые методы обработки комплексной информации и принятия решений на основе интеллектуальных многоагентных систем» (№ госрегистрации 20140547),
- ❸ ГПНИ «Информатика и космос, научное обеспечение безопасности и защиты от чрезвычайных ситуаций» по заданию «Методы и алгоритмы интеллектуальной обработки и анализа большого объема данных на основе нейронных сетей глубокого доверия»
(задание 1.6.05, № госрегистрации 20163595),
- ❹ НИР «Методы и алгоритмы построения интеллектуальных систем анализа и обработки данных», этап «Разработка гибридных интеллектуальных систем на основе нейросимволического подхода»,
- ❺ НИР БРФФИ «Модели и исследование 3-D оцифровки на основе фактических данных и анализа гетерогенных данных» (№ Ф22КИ-046 от 05.11.2021 г.).

Апробация результатов диссертации

Международные конференции:

- ① Открытые семантические технологии проектирования интеллектуальных систем (*Минск, 2018-2023*);
- ② International Conference on Neural Networks and Artificial Intelligence (*Брест, 2014*);
- ③ Информационное, программное и техническое обеспечение систем управления организационно-технологическими комплексами (*Луцк, 2015*);
- ④ 8th International Joint Conference on Computational Intelligence (IJCCI) (*Порто, 2016*);
- ⑤ 8th, 9th, 11th IEEE International Conference on Intelligent Data Acquisition and Advanced Computing Systems: Technology and Applications (IDAACS) (*Варшава, 2015; Бухарест, 2017; Краков, 2021*);
- ⑥ International Scientific-Practical Conference Problems of Infocommunications. Science and Technology (PIC S&T) (*Харьков, 2018*);
- ⑦ International Conference on Pattern Recognition and Information Processing (PRIP) (*Минск, 2019*);

Республиканские конференции:

- Вычислительные методы, модели и образовательные технологии (*Брест, 2013-2016, 2019*)
- Современные проблемы математики и вычислительной техники (*Брест, 2015, 2019, 2021*)

Опубликованность результатов диссертации (1)

По теме диссертационной работы опубликовано **30 печатных работ** (9,48 авторских листа):

- 11 статей в научных журналах (5,35 авторских листа);
- 5 статей в сборниках материалов научных конференций (0,48 авторских листа), включенных в системы международного цитирования (Scopus, Web of Science и IEEE Xplore digital);
- 14 статей в сборниках материалов научных конференций (3,65 авторских листа).

Опубликованность результатов диссертации (2)

Статьи в рецензируемых научных журналах

- ① Golovko, V. Learning Technique for Deep Belief Neural Networks / V. Golovko, A. Kroshchanka, U. Rubanau, S. Jankowski // Springer. — 2014. — Vol. 440. Communication in Computer and Information Science — P. 136–146.
- ② Головко, В. А. Персептроны и нейронные сети глубокого доверия: обучение и применение / В. А. Головко, А. А. Крощенко // Вестник БрГТУ. — Брест, 2014. — Т. 5. — С. 2–12.
- ③ Головко, В. А. Метод обучения нейронной сети глубокого доверия и применение для визуализации данных / В. А. Головко, А. А. Крощенко // Комп'ютерно інтегровані технології: освіта, наука, виробництво. — Луцк, 2015. — Вып. 19. — С. 6–12.
- ④ Golovko, V. The nature of unsupervised learning in deep neural networks: A new understanding and novel approach / V. Golovko, A. Kroshchanka, D. Treadwell // Optical Memory and Neural Networks. — Pleiades Publishing, 2016. — P. 127–141.
- ⑤ Головко, В. А. Теория глубокого обучения: конвенциональный и новый подход / В. А. Головко, А. А. Крощенко, М. В. Хацкевич // Вестник БрГТУ. — Брест, 2016. — № 5. — С. 7–16.

Опубликованность результатов диссертации (3)

- ⑥ Головко, В. А. Интеграция искусственных нейронных сетей с базами знаний / В. А. Головко, В. В. Голенков, В. П. Иващенко, В. В. Таберко, Д. С. Шаток, А. А. Крощенко, М. В. Ковалёв // Онтология проектирования. — EBSCO Publishing, 2018. — Т. 8. — № 3(29). — С. 366–386.
- ⑦ Крощенко, А. А. Реализация нейросетевой системы распознавания маркировки продукции / А. А. Крощенко, В. А. Головко // Вестник БрГТУ. — Брест, 2019. — № 5. — С. 9–12.
- ⑧ Golovko, V. Brands and caps labeling recognition in images using deep learning / V. Golovko, A. Kroshchanka, E. Mikhno // International Conference on Pattern Recognition and Information Processing. — Springer, Cham, 2019. — P. 35–51.
- ⑨ Golovko, V. Deep convolutional neural network for detection of solar panels / V. Golovko, A. Kroshchanka, E. Mikhno, M. Komar, A. Sachenko // Data-Centric Business and Applications. — Springer, Cham, 2021. — P. 371–389.
- ⑩ Golovko, V. A. Deep Neural Networks: Selected Aspects of Learning and Application / V. A. Golovko, A. A. Kroshchanka, E. V. Mikhno // Pattern Recognition and Image Analysis. — Pleiades Publishing, 2021. — Vol. 31. — No 1. — P. 132–143.

Опубликованность результатов диссертации (4)

- 11 Kroshchanka, A. A. Method for Reducing Neural-Network Models of Computer Vision / A. A. Kroshchanka, V. A. Golovko, M. Chodyka // Pattern Recognition and Image Analysis. — Pleiades Publishing, 2022. — Vol. 32. — No 2. — P. 294–300.

Статьи в сборниках материалов научных конференций, включенных в системы международного цитирования (Scopus, Web of Science и IEEE Xplore digital)

- 12 Golovko, V. A New Technique for Restricted Boltzmann Machine Learning / A. Kroshchanka, V. Turchenko, S. Jankowski, D. Treadwell // Proceedings of the 8th IEEE International Conference IDAACS–2015, Warsaw 24–26 September 2015. — Warsaw, 2015. — P. 182–186.
- 13 Golovko, V. Theoretical Notes on Unsupervised Learning in Deep Neural Networks / V. Golovko, A. Kroshchanka // Proceedings of the 8th International Joint Conference on Computational Intelligence (IJCCI 2016). — SCITEPRESS, 2016. — P. 91–96.
- 14 Golovko, V. Convolutional neural network based solar photovoltaic panel detection in satellite photos / V. Golovko, S. Bezobrazov, A. Kroshchanka, A. Sachenko, M. Komar, A. Karachka // 9th IEEE International Conference on Intelligent Data Acquisition and Advanced Computing Systems: Technology and Applications (IDAACS). — IEEE, 2017. — Vol. 1. — P. 14–19.

Опубликованность результатов диссертации (5)

- 15 Golovko, V. Development of solar panels detector / V. Golovko, A. Kroshchanka, S. Bezobrazov, A. Sachenko, M. Komar, O. Novosad // International Scientific-Practical Conference Problems of Infocommunications. Science and Technology (PIC S&T). — IEEE, 2018. — P. 761–764.
- 16 Kroshchanka, A. The Reduction of Fully Connected Neural Network Parameters Using the Pre-training Technique / A. Kroshchanka, V. Golovko // 11th IEEE International Conference on Intelligent Data Acquisition and Advanced Computing Systems: Technology and Applications (IDAACS). — IEEE, 2021. — Vol. 2. — P. 937–941.

Статьи в сборниках материалов научных конференций

- 1 Kroshchanka, A. Neural network component of the product marking recognition system on the production line / A. Kroshchanka, D. Ivaniuk // Open Semantic Technologies for Intelligent Systems (OSTIS-2021). — Minsk : BSUIR, 2021. — P. 219–224.
- 2 Kroshchanka, A. Reduction of neural network models in intelligent computer systems of a new generation / A. Kroshchanka // Open Semantic Technologies for Intelligent Systems (OSTIS-2023). — Minsk : BSUIR, 2023. — P. 127–132.

СПАСИБО ЗА ВНИМАНИЕ!