

**КРОЩЕНКО Александр Александрович**

# **Методы обучения глубоких нейронных сетей для задач компьютерного зрения**

диссертация на соискание

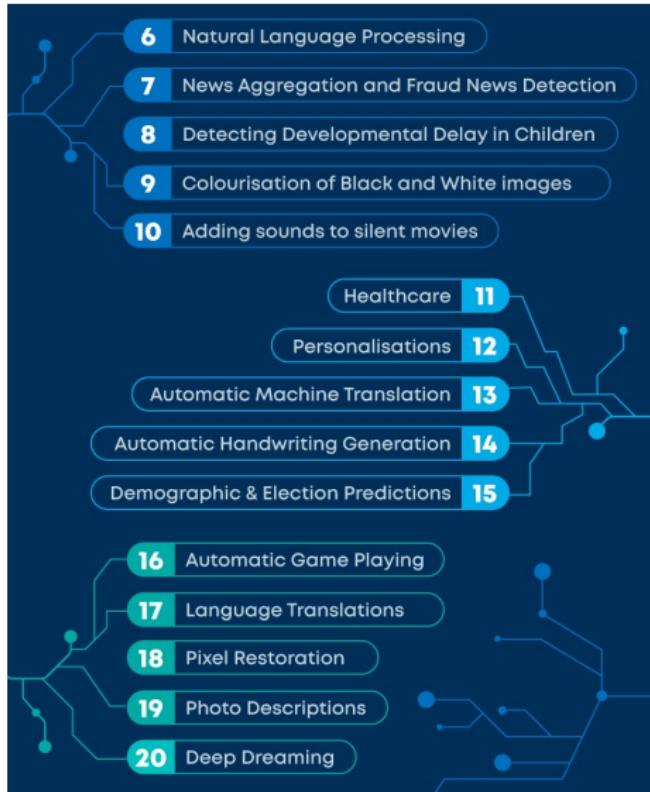
ученой степени кандидата технических наук по специальности  
05.13.17 – «Теоретические основы информатики»

Научный руководитель:  
д.т.н., профессор  
Головко В.А.

Брест 2024

# Актуальность (1)

Актуальность обучения глубоких нейронных сетей обусловлена растущим количеством приложений, в которых применяются эти модели.



## Актуальность (2)

К сожалению, в настоящее время одним из основных подходов при обучении глубоких нейросетей является использование зарекомендовавших себя методов при повышенных требованиях к количеству обучающих данных, что приводит к невозможности обучения таких моделей при аппаратных ограничениях. Тем не менее сложность самих моделей продолжает расти.

- AlexNet
- VGG16
- ResNet-50
- NASNet
- SENet

# Объект и предмет исследований

## Цель

**Разработка эффективных методов и алгоритмов для обучения глубоких нейронных сетей, используемых для решения задач компьютерного зрения, включающих распознавание маркировки продукции на конвейерной линии и определение наличия солнечных панелей на аэрофотоснимках.**

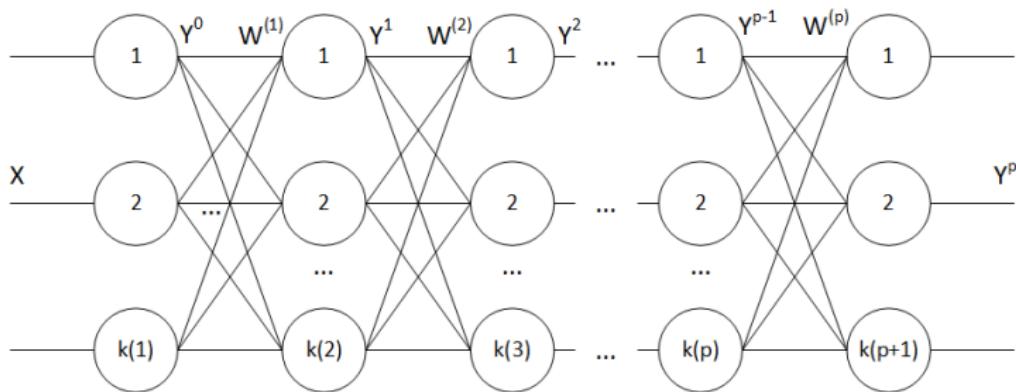
## Объект исследований

Нейросетевые системы компьютерного зрения

## Предмет исследований

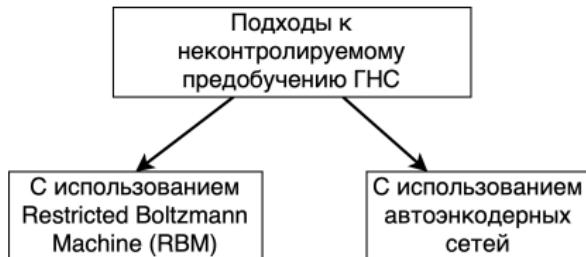
Методы и алгоритмы обучения глубоких нейронных сетей и их применение к задачам компьютерного зрения

# Методы обучения ГНС

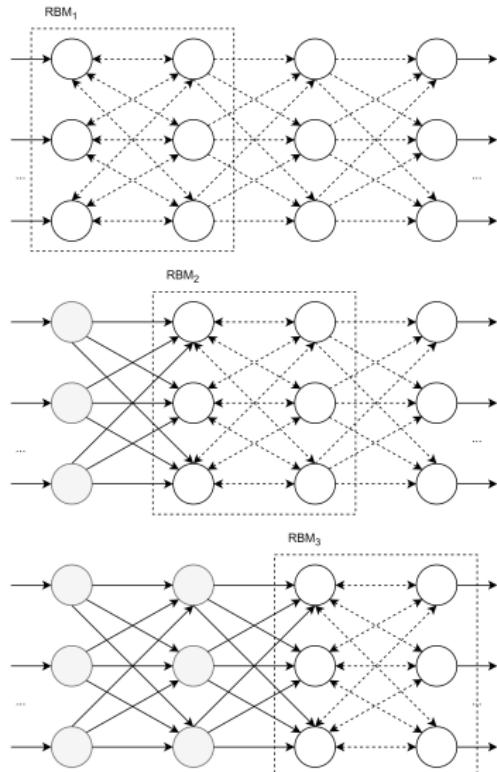
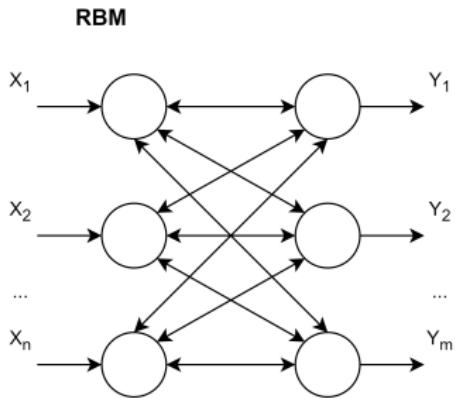


Методы обучения ГНС используют предварительное обучение (предобучение) в качестве этапа инициализирующей настройки параметров модели

- ❶ I тип – С использованием неконтролируемого предобучения;
- ❷ II тип – С использованием предобучения на большой обучающей выборке.



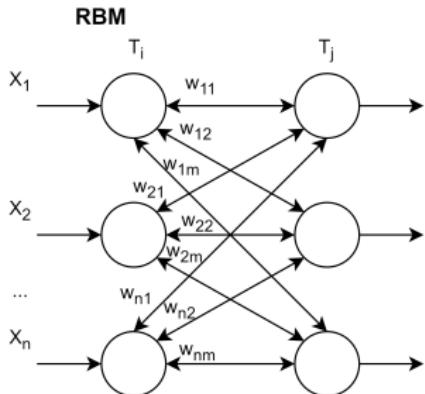
# Обучение с использованием неконтролируемого предобучения на основе RBM



Этапы обучения:

- 1 Послойное неконтролируемое предобучение нейронной сети;
- 2 Настройка синаптических связей всей сети («доводка» параметров);

# Обучение RBM



$$\ln P(x) = \ln \sum_y e^{-E(x,y)} - \ln \sum_{x,y} e^{-E(x,y)}$$

Обучение в процессе реализации процедуры CD (Contrastive Divergence):

$$x(0) \rightarrow y(0) \rightarrow x(1) \rightarrow y(1) \rightarrow \dots \\ \rightarrow x(k) \rightarrow y(k)$$

Правила обучения (случай CD-k)

$$w_{ij}(t+1) = w_{ij}(t) + \alpha(x_i(0)y_j(0) - x_i(k)y_j(k))$$

$$T_i(t+1) = T_i(t) + \alpha(x_i(0) - x_i(k))$$

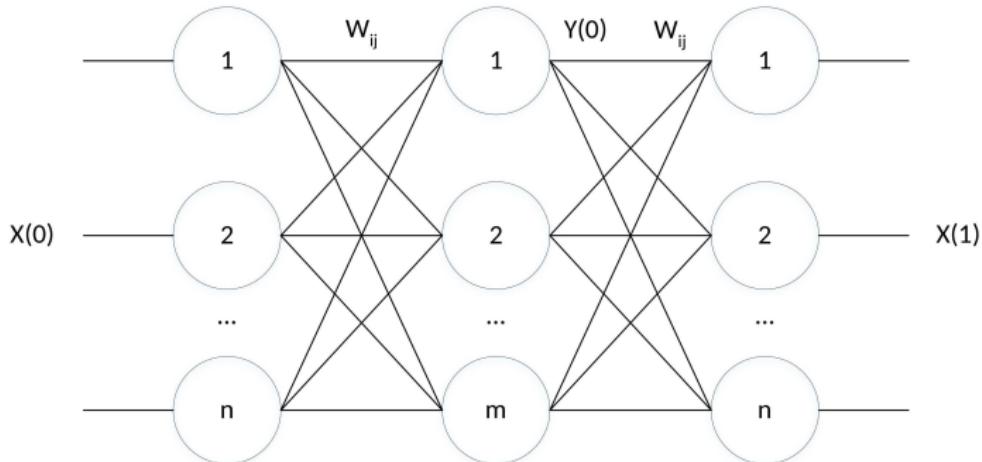
$$T_j(t+1) = T_j(t) + \alpha(y_j(0) - y_j(k)).$$

# Положения, выносимые на защиту (1)

1

**Метод обучения ограниченной машины Больцмана**, базирующийся на эквивалентности максимизации функции правдоподобия распределения входных данных в пространстве синаптических связей и минимизации суммарной квадратичной ошибки сети при использовании линейных нейронов, что позволяет **расширить класс обучаемых моделей и повысить обобщающую способность глубоких нейронных сетей**.

# Альтернативное представление RBM (1)



$$\begin{aligned} S_j(0) &= \sum_i w_{ij} x_i(0) + T_j \\ y_j(0) &= F(S_j(0)) \end{aligned}$$

$$\begin{aligned} S_i(1) &= \sum_j w_{ij} y_j(0) + T_i \\ x_i(1) &= F(S_i(1)) \end{aligned}$$

$$\begin{aligned} \dots \\ S_i(k) &= \sum_j w_{ij} y_j(k-1) + T_i \\ x_i(k) &= F(S_i(k)) \end{aligned}$$

$$\begin{aligned} \dots \\ S_j(k) &= \sum_i w_{ij} x_i(k) + T_j \\ y_j(k) &= F(S_j(k)) \end{aligned}$$

## Критерии минимизации

$$E_s(k) = \frac{1}{2L} \left( \sum_{l=1}^L \sum_{j=1}^m \sum_{p=1}^k (y_j^l(p) - y_j^l(p-1))^2 + \sum_{l=1}^L \sum_{i=1}^n \sum_{p=1}^k (x_i^l(p) - x_i^l(p-1))^2 \right)$$

$$CE_v(k) = -\frac{1}{L} \sum_{l=1}^L \sum_{p=1}^k \sum_{i=1}^n x_i^l(p-1) \log(x_i^l(p)) + (1 - x_i^l(p-1)) \log(1 - x_i^l(p))$$

$$CE_h(k) = -\frac{1}{L} \sum_{l=1}^L \sum_{p=1}^k \sum_{j=1}^m y_j^l(p-1) \log(y_j^l(p)) + (1 - y_j^l(p-1)) \log(1 - y_j^l(p))$$

$$CE_s(k) = CE_h(k) + CE_v(k)$$

# Теоремы об эквивалентности

**Теорема 1.** Максимизация функции правдоподобия распределения данных  $P(x)$  в пространстве синаптических связей ограниченной машины Больцмана эквивалентна минимизации суммарной квадратичной ошибки сети в том же пространстве при использовании линейных нейронов.

**Теорема 4.** Максимизация функции правдоподобия распределения входных данных  $P(x)$  эквивалентна минимизации кросс-энтропийной целевой функции  $CE_s(k)$  в одном и том же пространстве синаптических весов ограниченной машины Больцмана.

**Теорема 5.** Максимизация функции правдоподобия распределения входных данных  $P(x)$  эквивалентна минимизации кросс-энтропийной функции и специальному случаю минимизации среднеквадратичной ошибки в одном и том же пространстве синаптических весов ограниченной машины Больцмана:

$$\max(\ln P(x)) = \min(CE_s) = \min(E_s)$$

## Метод обучения RBM: последовательное обучение

Случай CD-1:

$$w_{ij}(t+1) = w_{ij}(t) - \alpha((y_j(1) - y_j(0))F'(S_j(1))x_i(1) + (x_i(1) - x_i(0))F'(S_i(1))y_j(0)),$$

$$T_i(t+1) = T_i(t) - \alpha(x_i(1) - x_i(0))F'(S_i(1)),$$

$$T_j(t+1) = T_j(t) - \alpha(y_j(1) - y_j(0))F'(S_j(1)).$$

Случай CD-k:

$$w_{ij}(t+1) = w_{ij}(t) - \alpha \left( \sum_{p=1}^k (y_j(p) - y_j(p-1))x_i(p)F'(S_j(p)) + (x_i(p) - x_i(p-1))y_j(p-1)F'(S_i(p)) \right)$$

$$T_i(t+1) = T_i(t) - \alpha \left( \sum_{p=1}^k (x_i(p) - x_i(p-1))F'(S_i(p)) \right),$$

$$T_j(t+1) = T_j(t) - \alpha \left( \sum_{p=1}^k (y_j(p) - y_j(p-1))F'(S_j(p)) \right),$$

# Метод обучения RBM: групповое обучение (1)

Случай CD-1:

$$w_{ij}(t+1) = w_{ij}(t) - \frac{\alpha}{L} \left( \sum_{l=1}^L (y_j^l(1) - y_j^l(0)) x_i^l(1) F'(S_j^l(1)) + (x_i^l(1) - x_i^l(0)) y_j^l(0) F'(S_i^l(1)) \right),$$

$$T_i(t+1) = T_i(t) - \frac{\alpha}{L} \left( \sum_{l=1}^L (x_i^l(1) - x_i^l(0)) F'(S_i^l(1)) \right),$$

$$T_j(t+1) = T_j(t) - \frac{\alpha}{L} \left( \sum_{l=1}^L (y_j^l(1) - y_j^l(0)) F'(S_j^l(1)) \right)$$

## Метод обучения RBM: групповое обучение (2)

Случай CD- $k$ :

$$w_{ij}(t+1) = w_{ij}(t) - \frac{\alpha}{L} \left( \sum_{l=1}^L \sum_{p=1}^k (y_j^l(p) - y_j^l(p-1)) x_i^l(p) F'(S_j^l(p)) + (x_i^l(p) - x_i^l(p-1)) y_j^l(p-1) F'(S_i^l(p)) \right)$$
$$T_i(t+1) = T_i(t) - \frac{\alpha}{L} \left( \sum_{l=1}^L \sum_{p=1}^k (x_i^l(p) - x_i^l(p-1)) F'(S_i^l(p)) \right),$$
$$T_j(t+1) = T_j(t) - \frac{\alpha}{L} \left( \sum_{l=1}^L \sum_{p=1}^k (y_j^l(p) - y_j^l(p-1)) F'(S_j^l(p)) \right)$$

# Метод обучения CRBM: последовательное обучение

Случай CD-1:

$$w_{ij}(t+1) = w_{ij}(t) - \alpha((y_j(1) - y_j(0))F'(S_j(1)) \circledast x_i(1) + (x_i(1) - x_i(0))F'(S_i(1)) \circledast y_j(0)),$$

$$T_i(t+1) = T_i(t) - \alpha(x_i(1) - x_i(0))F'(S_i(1)),$$

$$T_j(t+1) = T_j(t) - \alpha(y_j(1) - y_j(0))F'(S_j(1)).$$

Случай CD- $k$ :

$$w_{ij}(t+1) = w_{ij}(t) - \alpha \left( \sum_{p=1}^k (y_j(p) - y_j(p-1))F'(S_j(p)) \circledast x_i(p) + (x_i(p) - x_i(p-1))F'(S_i(p)) \circledast y_j(p-1) \right)$$

$$T_i(t+1) = T_i(t) - \alpha \left( \sum_{p=1}^k (x_i(p) - x_i(p-1))F'(S_i(p)) \right),$$

$$T_j(t+1) = T_j(t) - \alpha \left( \sum_{p=1}^k (y_j(p) - y_j(p-1))F'(S_j(p)) \right),$$

# Сравнение методов: используемые выборки



Характеристики:

## MNIST

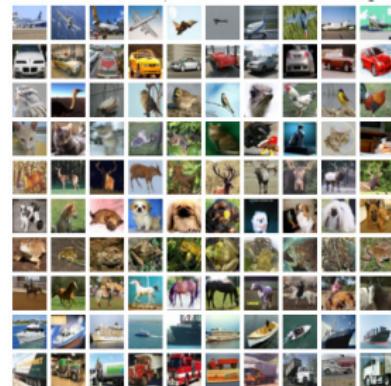
Количество классов: 10

Обучающая часть: 50.000 из.

Валидационная часть: 10.000 из.

Размеры изображений: 28X28

Цветовая модель: Grayscale



Характеристики:

## CIFAR10/CIFAR100

Количество классов: 10/100

Обучающая часть: 50.000 из.

Валидационная часть: 10.000 из.

Размеры изображений: 32X32

Цветовая модель: RGB

# Используемые программные средства реализации

- 1 Python

## Условные обозначения для исследуемых моделей

# Сравнение методов (MNIST): параметры эксперимента

## Параметры модели:

Параметр	Значение
Архитектура	40X5X5 – 40X5X5 – 640X320 – 320X160 – 160X10
Функция активации	ReLU
Функция активации на последнем слое	Softmax
Начальная инициализация параметров	Нормальное распределение
Общее число параметров модели	299.170

## Параметры обучения:

Этап	Параметр	Значение
Предобучение	Скорость обучения	0,000125
	Размер мини-батча	128
	Моментный параметр	[0,5; 0,9]
	Количество эпох обучения	30
Обучение	Скорость обучения	0,001
	Размер мини-батча	128
	Моментный параметр	0,9
	Количество эпох обучения	50

# Сравнение методов (MNIST): результаты

Метод обучения	Эффективность, %
BP	99.367
REBA	99.371
HREBA	<b>99.458</b>
C-RBM	99.447

- BP – обучение без предобучения;
- REBA – обучение с предобучением (предлагаемый подход);
- HREBA – обучение с предобучением (гибридный подход);
- C-RBM – обучение с классическим методом предобучения).

Лучший результат: **99.53** (HREBA)

При обучении с помощью гибридного метода первый слой глубокой нейронной сети обучался как RBM с использованием классического метода обучения, а все последующие обучались предложенным методом.

# Сравнение методов (CIFAR10): параметры эксперимента

## Параметры модели:

Параметр	Значение
Архитектура	64X5X5 – 32X5X5 – 800X128 – 128X10 / 128X100
Функция активации	ReLU - Tanh - ReLU
Функция активации на последнем слое	Softmax
Начальная инициализация параметров	Нормальное распределение
Общее число параметров модели	159.914

## Параметры обучения:

Этап	Параметр	Значение
Предобучение	Скорость обучения	0,000125
	Размер мини-батча	128
	Моментный параметр	[0,5; 0,9]
	Количество эпох обучения	30
Обучение	Скорость обучения	0,001
	Размер мини-батча	128
	Моментный параметр	0,9
	Количество эпох обучения	25

# Сравнение методов (CIFAR10): результаты

Метод обучения	Эффективность, %
BP	69.74
REBA	71.20
HREBA	<b>71.59</b>
C-RBM	71.51

- BP – обучение без предобучения;
- REBA – обучение с предобучением (предлагаемый подход);
- HREBA – обучение с предобучением (гибридный подход);
- C-RBM – обучение с классическим методом предобучения).

Лучший результат: **72.32** (HREBA)

# Сравнение методов (CIFAR100): результаты

Метод обучения	Эффективность, %
BP	36.83
REBA	38.9
HREBA	<b>39.86</b>
C-RBM	39.71

- BP – обучение без предобучения;
- REBA – обучение с предобучением (предлагаемый подход);
- HREBA – обучение с предобучением (гибридный подход);
- C-RBM – обучение с классическим методом предобучения).

Лучший результат: **40.26** (HREBA)

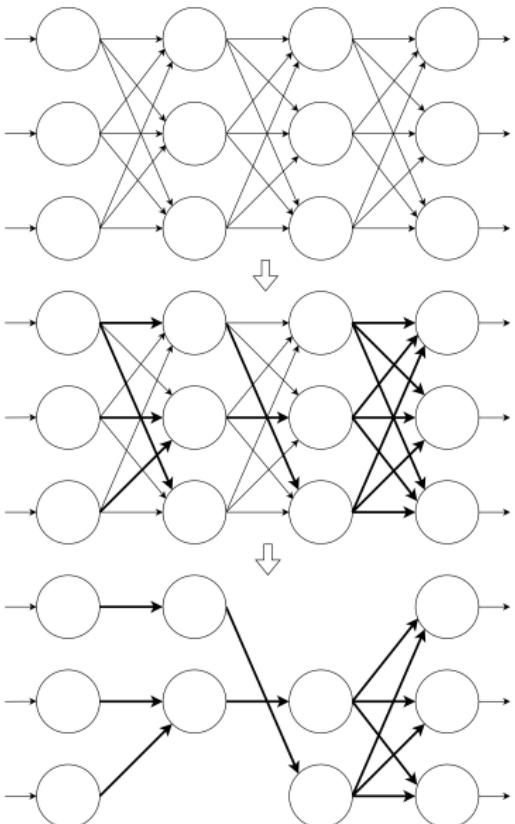
## Положения, выносимые на защиту (2)

2

**Алгоритм редуцирования параметров глубокой нейронной сети**, базирующийся на неконтролируемом предобучении сети, что позволяет упростить ее архитектуру (путем сокращения числа настраиваемых параметров модели) без потери обобщающей способности.

# Алгоритм редуцирования параметров

- 1 Неконтролируемое предобучение НС, начиная с первого слоя;
- 2 Обнуление параметров НС, значения которых попадают в интервал  $[-t, t]$  для заданного  $t > 0$ ;
- 3 Архитектурная реконфигурация НС. для каждого  $i$ -того слоя НС, кроме первого и последнего:
  - если вектор-столбец  $j$  матрицы весовых коэффициентов  $W_i$  слоя нулевой, то удалить  $j$ -тый вектор-столбец из  $W_i$  и удалить  $j$ -тую вектор-строку из  $W_{i+1}$
  - если вектор-строка  $k$  матрицы весовых коэффициентов нулевая, то удалить  $k$ -тую строку из  $W_i$  и удалить  $k$ -тый столбец из матрицы  $W_{i-1}$
- 4 Тонкая настройка синаптических связей полученной упрощенной архитектуры.



# Алгоритм редуцирования: параметры эксперимента

Таблица 1: Основные параметры обучения

Этап	Параметр	Значение
Обучение	Скорость обучения	0.05-0.1
	Размер мини-батча	100
	Моментный параметр	0.9
	Количество эпох обучения	50-100
Предобучение	Скорость обучения	0.05-0.2
	Размер мини-батча	32-100
	Моментный параметр	[0.5, 0.9]
	Количество эпох обучения	10

# Алгоритм редуцирования: результаты

784-800-800-10

Тип	Эффективность, %, C-RBM / REBA	Количество параметров, C-RBM / REBA	Редуцировано параметров, %, C-RBM / REBA
без редуц.	<b>98.63</b> / 98.33	1276810 / 1276810	0/0
t=0.2	<b>98.61</b> / 98.27	<b>233760</b> / 279635	<b>81.69</b> / 78.1
t=0.5	98.03 / <b>98.05</b>	<b>32524</b> / 32817	<b>97.45</b> / 97.43
t=0.8	<b>97.1</b> / 96.48	17061 / <b>12217</b>	98.66 / <b>99.04</b>

784-1600-1600-800-800-10

Тип	Эффективность, %, C-RBM / REBA	Количество параметров, C-RBM / REBA	Редуцировано параметров, %, C-RBM / REBA
без редуц.	<b>98.76</b> / 98.37	5747210 / 5747210	0/0
t=0.2	98.51 / <b>98.55</b>	<b>710734</b> / 781103	<b>87.63</b> / 86.41
t=0.5	98.01 / <b>98.03</b>	<b>54709</b> / <b>43867</b>	99.05 / <b>99.24</b>
t=0.8	<b>96.9</b> / 93.08	25385 / <b>14914</b>	99.56 / <b>99.74</b>

# Результаты архитектурной реконфигурации моделей

Исходная модель: 784-800-800-10

Параметр	Редуцированная
t=0.2	784-800-556-10
t=0.5	784-710-422-10
t=0.9	784-91-114-10

Исходная модель: 784-1600-1600-800-800-10

Параметр	Редуцированная
t=0.2	784-889-192-686-221-10
t=0.5	784-464-157-567-182-10
t=0.9	784-17-101-118-50-10

# Положения, выносимые на защиту (3)

3

**Нейросетевые системы компьютерного зрения,**  
базирующиеся на использовании предобученных моделей для  
решения задач классификации и детекции – система  
распознавания (в реальном режиме времени) **маркировки**  
**продукта на производственной линии и система**  
**обнаружения солнечных панелей на аэрофотоснимках**  
(включая снимки низкого разрешения) с точностью до 87,46%.

# Система распознавания маркировки

## Цель разработки

Разработать систему проверки корректности нанесения маркировки на продукцию, производимую ОАО «Савушкин продукт»

## Актуальность

Контроль качества маркировки необходим для контроля за свежестью продукции как со стороны покупателей, так и со стороны обслуживающего персонала супермаркетов, поскольку в большинстве случаев визуальная оценка оказывается проще и быстрее применения специализированных технических средств.

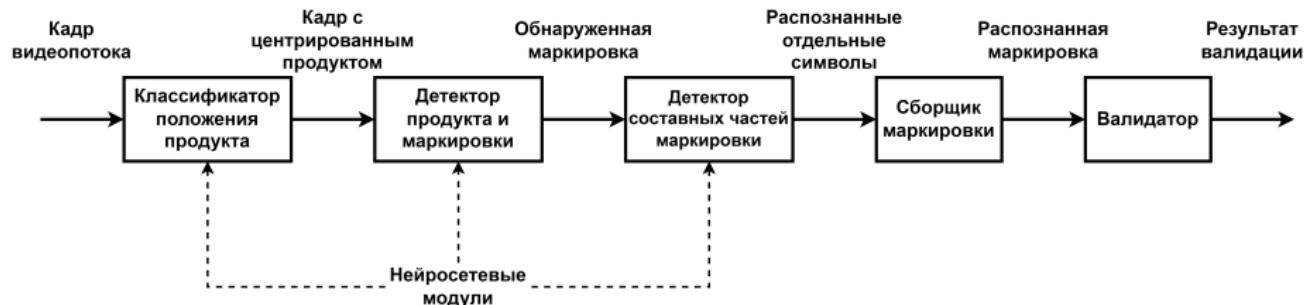


## Возможные ошибки, допускаемые при нанесении маркировки

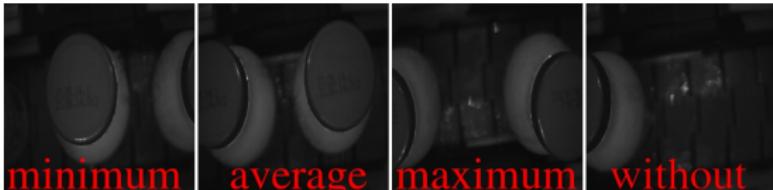
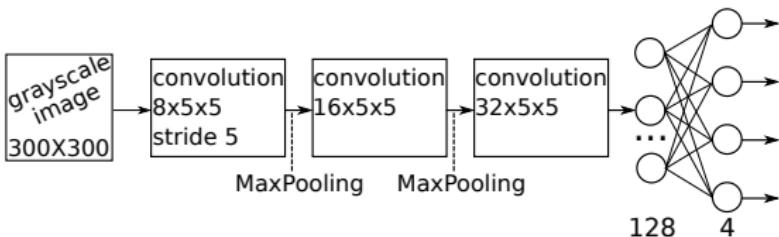
- Отсутствие краски в печатающем устройстве;
- Смазанность маркировки;
- Ошибочная дата в маркировке.

Первый тип ошибок может быть представлен различными случаями, такими как полное отсутствие маркировки или отсутствие какой-либо ее части.

# Структура системы и базовые модули

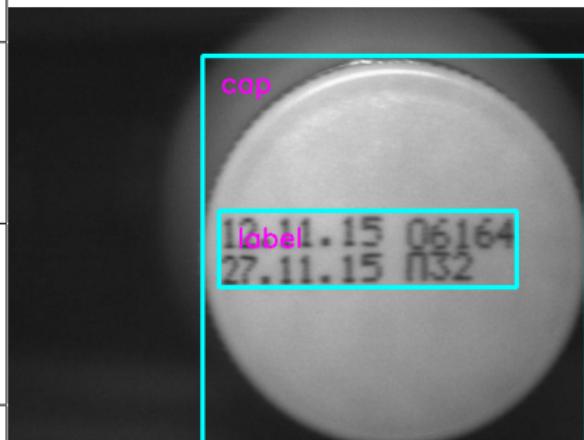


- ❶ Классификатор положения продукта
- ❷ Детектор продукта и маркировки (SSD-MobileNet)
- ❸ Детектор составных частей маркировки (SSD-MobileNet)



# Результаты обучения и тестирования моделей (1)

Модель	Выборка	Тест., %
Классификатор положения продукта	Обучающая часть: 4.886 Валидационная часть: 1.303	93,27
Детектор продукта и маркировки	Обучающая часть: 652 Валидационная часть: 163	99,03
Детектор отдельных символов	Обучающая часть: 33402 (SVHN) + 825 Валидационная часть: 13068 (SVHN) + 275	92,43



# Система обнаружения солнечных панелей на аэрофотоснимках

## Цель разработки

Разработать систему детекции солнечных панелей на фотоснимках, полученных из выборки, собранной из Google Maps

## Актуальность

Необходимость разработки специализированных решений для детекции панелей обусловлена стремлением компаний получать информацию об применении данной технологии и тем самым создавать целевое предложение.

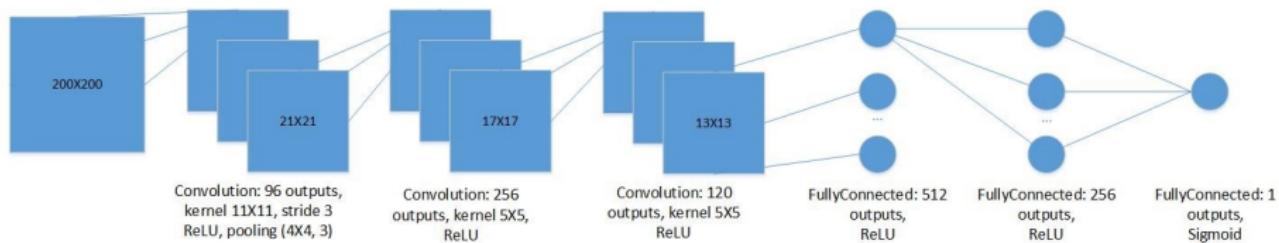
Предлагаемый алгоритм обнаружения панелей включает два основных этапа, на каждом из которых используется предобученная глубокая нейронная сеть:

- 1 Оценка наличия солнечной панели на аэрофотоснимке
- 2 Локализация солнечной панели

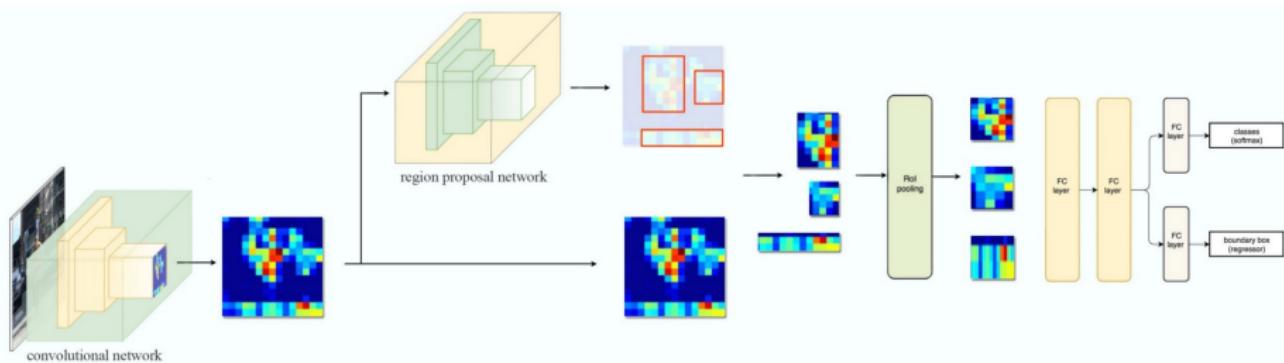


# Применяемые модели

## Классификатор для оценки наличия панели



## Модель для детекции панели (на базе Faster R-CNN)



## Результаты обучения и тестирования моделей (2)

Модель	Выборка	Тест., %
Классификатор наличия	Обучающая часть: 2.677 Валидационная часть: 670	87,46
Детектор солнечной панели	Обучающая часть: 800 Валидационная часть: 200	92,99



# Связь работы с научными программами

- 1 НИР МОРБ «Алгоритмы интеллектуального анализа и обработки больших объемов данных на основе нейронных сетей глубокого доверия» (ГБ 15/203, № госрегистрации 20150743),
- 2 ГПНИ «Информатика и космос, научное обеспечение безопасности и защиты от чрезвычайных ситуаций» по заданию «Нейросетевые методы обработки комплексной информации и принятия решений на основе интеллектуальных многоагентных систем» (№ госрегистрации 20140547),
- 3 ГПНИ «Информатика и космос, научное обеспечение безопасности и защиты от чрезвычайных ситуаций» по заданию «Методы и алгоритмы интеллектуальной обработки и анализа большого объема данных на основе нейронных сетей глубокого доверия» (задание 1.6.05, № госрегистрации 20163595),
- 4 НИР «Методы и алгоритмы построения интеллектуальных систем анализа и обработки данных», этап «Разработка гибридных интеллектуальных систем на основе нейросимволического подхода» (решение НТС УО «Брестский государственный технический университет» от 12.11.2021, протокол № 6, № 22202052022070),
- 5 НИР БРФФИ «Модели и исследование 3-Д оцифровки на основе фактических данных и анализа гетерогенных данных» (№ Ф22КИ-046 от 05.11.2021 г., № госрегистрации 20220090).

# Апробация результатов диссертации

## Международные конференции:

- ① Открытые семантические технологии проектирования интеллектуальных систем (*Минск, 2018-2023*);
- ② International Conference on Neural Networks and Artificial Intelligence (*Брест, 2014*);
- ③ Информационное, программное и техническое обеспечение систем управления организационно-технологическими комплексами (*Луцк, 2015*);
- ④ 8th International Joint Conference on Computational Intelligence (IJCCI) (*Порто, 2016*);
- ⑤ 8th, 9th, 11th IEEE International Conference on Intelligent Data Acquisition and Advanced Computing Systems: Technology and Applications (IDAACS) (*Варшава, 2015; Бухарест, 2017; Краков, 2021*);
- ⑥ International Scientific-Practical Conference Problems of Infocommunications. Science and Technology (PIC S&T) (*Харьков, 2018*);
- ⑦ International Conference on Pattern Recognition and Information Processing (PRIP) (*Минск, 2019*);

## Республиканские конференции:

- Вычислительные методы, модели и образовательные технологии (*Брест, 2013-2016, 2019*)
- Современные проблемы математики и вычислительной техники (*Брест, 2015, 2019, 2021*)

## Опубликованность результатов диссертации (1)

Основные результаты диссертационного исследования опубликованы в 30 научных работах, среди которых:

- 8 статей в научных изданиях в соответствии с пунктом 19 Положения о присуждении ученых степеней и присвоении ученых званий (общим объемом 3,87 авторского листа);
- 5 статей в других научных изданиях;
- 13 статей в сборниках материалов научных конференций;
- 4 тезисов.

## Опубликованность результатов диссертации (2)

### Статьи в научных рецензируемых изданиях, включенных в перечень изданий, и в иностранных научных изданиях

- ① Головко, В.А. Персептроны и нейронные сети глубокого доверия : обучение и применение / В.А. Головко, А.А. Крощенко // Вестник Брестского государственного технического университета. Физика, математика, информатика. — 2014. — № 5 (89). — С. 2—12.
- ② Golovko, V. The Nature of Unsupervised Learning in Deep Neural Networks : A New Understanding and Novel Approach / V. Golovko, A. Kroshchanka, D. Treadwell // Optical Memory and Neural Networks. — 2016. — Vol. 25, № 3. — P. 127–141.
- ③ Головко, В.А. Теория глубокого обучения : конвенциональный и новый подход / В.А. Головко, А.А. Крощенко, М.В. Хацкевич // Вестник Брестского государственного технического университета. Физика, математика, информатика. — 2016. — № 5 (101). — С. 7–16.
- ④ Крощенко, А.А. Реализация нейросетевой системы распознавания маркировки продукции / А.А. Крощенко, В.А. Головко // Вестник Брестского государственного технического университета. Физика, математика, информатика. — 2019. — № 5 (118). — С. 9–12.
- ⑤ Golovko, V.A. Deep Neural Networks : Selected Aspects of Learning and Application / V.A. Golovko, A.A. Kroshchanka, E.V. Mikhno // Pattern Recognition and Image Analysis. — 2021. — Vol. 31, № 1. — P. 132–143.

## Опубликованность результатов диссертации (3)

- ⑥ Kroshchanka, A. Neural network component of the product marking recognition system on the production line / A. Kroshchanka, D. Ivaniuk // Open Semantic Technologies for Intelligent Systems : research papers collection / Belar. State Univ. of Informatics and Radioelectr.; ed. : V.V. Golenkov (ed.-in-chief) [et al.]. — Minsk, 2021. — Iss. 5. — P. 219–224.
- ⑦ Kroshchanka, A.A. Method for Reducing Neural-Network Models of Computer Vision / A.A. Kroshchanka, V.A. Golovko, M. Chodyka // Pattern Recognition and Image Analysis. — Berlin, Heidelberg : Springer-Verlag, 2022. — Vol. 32, № 2. — P. 294–300.
- ⑧ Kroshchanka, A.A. Reduction of Neural Network Models in Intelligent Computer Systems of a New Generation / A. Kroshchanka // Open Semantic Technologies for Intelligent Systems (OSTIS-2023) : research papers collection / Belar. State Univ. of Informatics and Radioelectr.; ed. : V.V. Golenkov (ed.-in-chief) [et al.]. — Minsk, 2023. — Iss. 7. — P. 127–132.

### Статьи в других научных изданиях

- ① Головко, В.А. Метод обучения нейронной сети глубокого доверия и применение для визуализации данных / В.А. Головко, А.А. Крощенко // Комп'ютерно-інтегровані технології: освіта, наука, виробництво. — Луцьк, 2015. — № 19. — С. 6–12.

## Опубликованность результатов диссертации (4)

- ❷ Интеграция искусственных нейронных сетей с базами знаний / В.А. Головко, В.В. Голенков, В.П. Иващенко, В.В. Таберко, Д.С. Иванюк, А.А. Крощенко, М.В. Ковалёв // Онтология проектирования. — 2018. — Т. 8. — № 3 (29). — С. 366–386.
- ❸ Principles of decision-making systems building based on the integration of neural networks and semantic models / V. Golovko, A. Kroshchanka, V. Ivashenko, M. Kovalev, V. Taberko, D. Ivaniuk // Open Semantic Technologies for Intelligent Systems (OSTIS-2019) : research papers collection / Belar. State Univ. of Informatics and Radioelectr.; ed. : V.V. Golenkov (ed.-in-chief) [et al.]. — Minsk, 2019. — Iss. 3. — P. 91–102.
- ❹ Implementation of an intelligent decision support system to accompany the manufacturing process / V. Golovko, A. Kroshchanka, M. Kovalev, V. Taberko, D. Ivaniuk // Open Semantic Technologies for Intelligent Systems (OSTIS-2020) : research papers collection / Belar. State Univ. of Informatics and Radioelectr.; ed. : V.V. Golenkov (ed.-in-chief) [et al.]. — Minsk, 2020. — Iss. 4. — P. 175–182.
- ❺ Deep Convolutional Neural Network for Detection of Solar Panels / V. Golovko, A. Kroshchanka, E. Mikhno, M. Komar, A. Sachenko // Data-Centric Business and Applications. ICT Systems-Theory, Radio-Electronics, Information Technologies and Cybersecurity. — Cham: Springer International Publishing, 2021. — P. 371–389.

# Опубликованность результатов диссертации (5)

## Статьи в сборниках материалов научных конференций

- ❶ A Learning Technique for Deep Belief Neural Networks / V. Golovko, A. Kroshchanka, U. Rubanau, S. Jankowski // Neural Networks and Artificial Intelligence : proc. of the 8th Internat. Conf. ICNNNAI 2014, Brest, Belarus, June 3-6, 2014 / V. Golovko, A. Imada (eds.). — Springer, 2014. — P. 136–146.
- ❷ Головко, В.А. Применение нейронных сетей глубокого доверия для выделения семантически значимых признаков / В.А. Головко, А.А. Крощенко // Открытые семантические технологии проектирования интеллектуальных систем : материалы V Междунар. науч.-технич. конф. OSTIS-2015, Минск, 19-21 февраля 2015 г. / УО «Бел. гос. ун-т информатики и радиоэлектроники», ГУ «Администрация Парка высоких технологий»; редкол.: В.В. Голенков (отв. ред.) [и др.]. — Минск, 2015. — Р. 481–486.
- ❸ A New Technique for Restricted Boltzmann Machine Learning [Electronic resource] / V. Golovko, A. Kroshchanka, V. Turchenko, S. Jankowski, D. Treadwell // Proceedings of the 8th IEEE International Conference of Intelligent Data Acquisition and Advanced Computing Systems : Technology and Applications (IDAACS), Warsaw, Poland, Sept. 24-26, 2015 / Research Institute for Intelligent Computer Systems, Ternopil National Economic University and V.M. Glushkov Inst. of Cybernetics, National Academy for Sciences of Ukraine, Warsaw University of Technology. — P. 182–186. — Mode of access : <https://ieeexplore.ieee.org/document/7340725>. — Date of access : 05.06.2023.



СПАСИБО ЗА ВНИМАНИЕ!